

Est-ce que ce Tweet est drôle ? Détection automatique de tweets humoristiques

Florian Boudin¹ Adeline Granet² Alexis Linard²

(1) Laboratoire LINA, Université de Nantes, 2 rue de la Houssinière, BP 92208, 44322 Nantes, France

(2) Université de Nantes, 2 rue de la Houssinière, BP 92208, 44322 Nantes, France
florian.boudin@univ-nantes.fr, adeline.granet@etu.univ-nantes.fr, alexis.linard@etu.univ-nantes.fr

Résumé. Ici, un résumé en français (max. 150 mots).

Abstract. Here an abstract in English (max. 150 words).

Mots-clés : Ici une liste de mots-clés en français.

Keywords: Here a list of keywords in English.

1 Introduction

De nos jours, il n'y a plus de distinction nette entre la vie réelle et virtuelle. Il existe, chez les internautes, un besoin permanent de tout partager. Leurs succès, leurs échecs, leurs tracas, voir même leurs repas du midi prennent vie sur la toile, et ce sans aucune limite. Les outils les plus propices à cette déferlante d'informations sont les réseaux sociaux. Cet article s'intéresse à Twitter qui est rapidement devenu leader dans ce domaine avec plus de 500 millions d'utilisateurs.

Par son format limité à des publications de 140 caractères (appelé Tweet), Twitter demande aux utilisateurs de faire passer leurs émotions, leurs sentiments et leurs découvertes en étant le plus concis possible. C'est un fait, Twitter est une véritable mine d'informations grâce à la multitude de messages qui s'y trouvent, mais également à tout ce qui gravite autour. Car un tweet peut être retweeté(reposté) par d'autres utilisateurs, contenir des hashtags définissant parfois le thème dominant. Nous avons choisis de nous intéresser particulièrement aux tweets humoristiques.

Notre objectif est de développer un outil capable de détecter automatiquement si un tweet est drôle ou non. Voici un tweet que l'on souhaiterait classer : « Il court, il court le furet #Contrepeterie ». De toute évidence, celui-ci est drôle car comme le hashtag le mentionne c'est une contrepétie.

Des approches similaires ont déjà été réalisées dans le domaine anglophone comme (Raz, 2012; Barbosa & Feng, 2010), elles seront détaillées dans la section suivante 2. La section 3 sera consacrée à la méthode que nous avons suivie pour réaliser la classification des tweets avec les traits que nous avons sélectionnés. La section 4 décrira le corpus qui a servi à construire le modèle ainsi que l'utilisation de Weka et la section 5, les résultats obtenus.

2 Etat de l'art

Les idées d'exploitations de tweet ne manquent pas du côté anglophone. Celui qui a largement inspiré la méthode présentée ici est (Raz, 2012). Dans cet article, Yishay Raz propose une méthode de classification de tweets humoristiques en anglais selon le type de l'humour. Pour cela, il utilise un algorithme semi-supervisé qui prend en entrée des tweets annotés pour produire des ensembles avec des caractéristiques propres au classifieur. [...]

- Caractéristiques lexicales : les mots appartiennent à des lexiques particuliers, des entités nommées sont présentes, ou bien une ambiguïté se pose ;
- Caractéristiques morphologiques : analyse du temps des verbes, les mots existent-ils ;
- Phonologie : les mots sont-ils connus comme homophone ;

- Style : présence de smiley, ponctuation particulière, hashtag.

Cette approche est fortement intéressante. Malheureusement, une partie des caractéristiques nécessite d'avoir énormément de ressources de références. En français, il est difficile de trouver un lexique pour les mots vulgaires, du domaine gay, les entités nommées, les homophones, etc. L'évaluation de cette méthode a été réalisée en utilisant le site <http://www.funny-tweets.com> pour collecter un ensemble de tweets « drôles » ce qui a permis d'éviter un tri fastidieux à la main pour classer les tweets en drôle ou non. Depuis, ce site ne fonctionne plus. Nous avons donc cherché une alternative pour la collecte de tweets drôles francophones.

L'article de (Barbosa & Feng, 2010) sur la détection automatique de sentiment émis dans les tweets, montre qu'il y a beaucoup de travaux réalisés dans ce sens que se soit à travers des articles de recherche ou bien des sites proposant de la détection de sentiments en temps réels de tweets. Sa méthode repose sur trois caractéristiques principalement : le POS tagging, la polarité et la syntaxe spécifique du tweet comme les liens, la ponctuations, les émoticônes, ainsi que la casse des mots.

Une caractéristique commune aux deux articles est l'analyse du style qui n'est pas dépendante des bases de connaissances de la langue et donc exploitable dans notre étude.

3 Méthode de classification utilisée

3.1 Le tweet

Comme cela a été mentionné plus tôt, Twitter permet de poster de courts messages de 140 caractères. Il y a certaines caractéristiques présentes dans le tweet qui sont intéressantes : l'utilisateur propriétaire qui est indiqué par 20 caractères commençant par le symbole "@" ; la mention ReTweeter avec le nom de l'utilisateur d'origine ; le hashtag "#ironie" est un mot clé donnant le thème du tweet ; les liens externes vers d'autres sources pour avoir la fin d'une blague par exemple "<http://bit.ly/114TdOF>". Parmi ces caractéristiques, un grand nombre seront exploités pour créer le modèle d'apprentissage comme cela est détaillé à la section suivante 3.2.

3.2 Les features

La tâche de classification consiste à séparer en deux classes distinctes les tweets : une classe "Drôle" et "Pas Drôle". Nous avons testé plusieurs algorithmes qui seront détaillés dans la section 3.3 Une méthode d'apprentissage non-supervisé est utilisé prenant en entrée un ensemble de tweets. Ce dernier va fournir différentes caractéristiques pour le classifieur multi-classe. Les caractéristiques étudiées sont de type lexicales, stylistiques et contextuelles.

Caractéristique lexicale

Lexique de mots : il a été construit à partir des tweets du corpus où chaque mot a été racinisé et auquel on a enlevé les mots creux et nettoyé le surplus comme les liens externes.

Caractéristique stylistique

- La présence de hashtag comme "#humour" : nous avons trouvé que les utilisateurs ajoutaient un "#humour" ou "#contre-pétie" pour identifier le thème sous-entendu dans leur message ;
- La présence de smiley content ou pas content au sein du tweet est observé. Par exemple "c'était pas moi ;)", la présence du smiley montre le caractère ironique de la phrase ;
- Le nombre de point d'exclamation est également pris en compte, par exemple dans une même phrase "je suis calme !" et "je suis calme !!!!!!!!!!" n'ont pas la même signification, et donne de l'intensité au message voir même de l'ironie dans notre cas.

Caractéristique contextuel

- Le nombre de mots dans le tweet ;
- Le nombre de ReTweet ;
- La longueur total du tweet ;
- Si il s'agit d'un retweet.

3.3 Les méthodes utilisés

Pour les méthodes de classification que nous avons utilisées dans Weka, nous avons pris le parti de garder certains des paramètres par défaut. **Naïvesbayes** C'est le modèle probabiliste le plus utilisé. Il met en avant l'indépendance entre chaque caractéristiques. Il utilise une hypothèse de distribution Gaussienne pour calculer la probabilité pour chaque caractéristique.

J48 C'est une méthode d'apprentissage par arbre de décision. Un arbre va être construit de façon récursif en séparant les données suivant des tests sur les features définis.

ZeroR Assigne simplement chaque valeur à la classe la plus commune (en examinant le corpus d'entraînement). Cela signifie que si les données sont à 55% de classe A, 10% de classe B, 5% de classe C etc... alors ZeroR trouvera 55% A. C'est le classifieur le plus "basique". C'est de fait la méthode nous donnant les plus faibles résultats obtenables.

MultilayerPerceptron Le Perceptron multicouche est un classifieur linéaire organisé en plusieurs couches au sein desquelles une information circule de la couche d'entrée vers la couche de sortie uniquement ; chaque couche est constituée d'un nombre variable de neurones, les neurones de la couche de sortie correspondant toujours aux sorties du système.

DecisionStump Consiste en un arbre de décision à une seul niveau. C'est un arbre avec une racine immédiatement connectés à ses feuilles. En outre, donne une prédiction sur une valeur d'un seul trait.

4 Le corpus

4.1 Corpus d'entraînement

Grâce à l'application twitter4j, un corpus de plus de 10 000 tweets a été réalisé. Ce corpus a été constitué à partir de tweets drôles et non drôles comme le montre le tableau suivant :

	Tweets Drôles	Tweets Pas Drôles
ReTweets	166	1019
ReTweetés	2817	4009
Non ReTweetés	2000	1273
Contrepétories	200	/
Autodérision	200	/
Total	4817	5282

TABLE 1 – Composition du corpus

Pour extraire des tweets, il est important de commencer par choisir des comptes tweeter. Ces comptes doivent contenir soit uniquement (ou grande partie puisqu'il est difficile d'être sur) des tweets "drôles" ou des tweets "pas drôles".

Pour les comptes supposés "drôles", nous avons effectué une sélection de 35 comptes. Nous nous sommes basés essentiellement sur le nom de l'utilisateur contenant des mots clés comme « humour » et « blague ». Voici des exemples de comptes que l'on a pu sélectionner « @100_blagues, @BlaguesCarambar, @BlagueJour », il est facile de supposer que les tweets seront tous à caractères humoristiques et surement drôles. D'autres comptes ont été choisis par rapport à leur notoriété. Ils sont connus pour rassembler des tweets « drôles » par leur ironie ou montrant l'autodérision de leur auteur comme sur @viedemerde.

Pour les comptes répertoriant les tweets dits "pas drôles", nous en avons choisi 28. Nous avons supposé que tous les comptes politiques comme « @elysee », journalistiques comme « @lemondefr, @LesEchos » ne contenaient pas de blagues, car ils sont supposés donner des informations sérieuses. Mais pour diversifier les domaines évoqués dans les tweets, nous avons ajouté des comptes commerciaux comme @m6, @nantesfr ou @conforama.

Ce corpus est utilisé pour entraîner le modèle d'apprentissage pour distinguer si un tweet est drôle ou non mais pas seulement. Il a été utilisé pour créer un lexique de mot caractéristique des tweets. Pour cela, tous les mots ont été extraits puis racinisés. A cette liste, les mots creux de langue française, soit une liste de 460 mots, ont été retirés. Chaque mot restant constitue une caractéristique, un trait.

4.2 Corpus de test

Pour constituer le corpus de test, nous avons extrait 250 tweets provenant des comptes des humoristes Gad Elmaleh, Florence Foresti et Cyprien (un youtubeur). Nous les avons choisis, car ils sont représentatifs de Twitter c'est-à-dire une grande majorité de tweets sur le quotidien et quelques tweets drôles. Plus que quiconque ils sont plus susceptibles de par leur métier de poster des tweets drôles .

Ce corpus a été réparti équitablement dans trois fichiers xml différents. Chaque fichier a été annoté par deux annotateurs, qui pour chaque tweet, devait indiquer si la mention "Drole" ou "PasDrole".

	Corpus d'entraînement	Corpus de test
Nbre de mot départ	?	?
Après nettoyage	?	?
Après racinisation	?	?

TABLE 2 – Constitutions des corpus

5 Phase d'évaluation

5.1 Mesures d'évaluation

5.2 Les résultats

faire un joli tableau, comparer à une baseline (mais laquelle ? par exemple 1 smiley = 1 tweet drole mais il faut justifier cette baseline)

6 Conclusion et discussion

Références

- BARBOSA L. & FENG J. (2010). Robust sentiment detection on twitter from biased and noisy data. p. 36–44 : Association for Computational Linguistics.
- RAZ Y. (2012). Automatic humor classification on twitter. p. 66–70 : The Association for Computational Linguistics.